

Meerkat-TRIZ 白皮书 v1.1

Meerkat-TRIZ: TRIZ 领域 LoRA 微调, 以及让它保持诚实的评测基础设施

🇺🇸 English | 🇨🇳 中文 Meerkat AI · 2026 年 7 月 · v1.1 (新增发布后异源评委终审, §5.2) 产物: 模型 · 基准 · 代码

摘要

我们发布 **Meerkat-TRIZ-v1**: 一个 LoRA 适配器 (181MB, $r=64$, 可训练参数占 0.24%), 在 Qwen3.6-35B-A3B (Gated DeltaNet $\times$ Gated Attention $\times$ 256 专家 MoE 的 thinking-native 混合架构) 上微调, 面向中文 TRIZ (发明问题解决理论) 问答。据我们所知, 这是 TRIZ 领域首个公开发布的 LLM 微调模型。

更具普适价值的贡献, 是评测系统在这一路上的遭遇。在五版本、评测驱动的迭代过程中, 我们发现并修复了三类各自足以反转或作废结论的测量学故障: 其一, **基线污染**——评测 harness 剥离了 thinking-native 基座所需的空 think 块, 导致基座 91/100 题输出为未闭合思考草稿, 微调相对基座的 judge 提升从伪影性的 $+1.00$ 反转为真实的 -0.30 ; 其二, **评委位置偏差极端化**——pairwise 评委位置不一致率达 0.87 , 是文献约 25pp 摆动的两倍多, 双序合并成为唯一有效口径; 其三, **双轨系统性分歧**——关键词轨与评委轨仅共享约 10% 方差, 迭代中曾出现两轨显著反向。第四类风险在发布后被量化: 其四, **同族评委膨胀**——异源评委终审 (Claude / GPT / Gemini, 协议逐字复刻, 299 题配对) 在 2/3 评委下确认了提升方向, 但量级仅为同族读数的约 1/4, 即头条数字中约 3/4 可归因于评委家族效应。在干净锚点下的诚实结论是: 在其原生 v5 金标口径上, 发布模型的 judge 轨相对基座有提升——三个外部评委中两个显著 ($+0.09 \sim +0.10$), 第三个无显著差异; 同族评委读数为 $+0.39$ [$+0.30, +0.49$]。跨评委共识最强的是定向修复的 concept_explanation (三个外部评委下全部显著)。关键词覆盖持平; 在较早的 v4 口径上与内部最强基线统计打平。我们同时发布模型、双金标基准与全部统计纪律机检化的评测 harness。

1. 引言

领域微调是一连串决策, 而每一环都由评测信号锻造: v2 是否优于 v1? 定向数据注入是否奏效? 是否发布? 信号一旦被污染, 下游每个决策都会“自信地错误”。

本白皮书完整记录了一次迭代战役——五个适配器版本、两代基准、一次公开发布——其中评测基础设施本身成了最主要的工程对象。我们沿两个方向讲述: 测量当时说了什么, 以及在每类测量故障被发现并修复之后, 它们实际上意味着什么。下文所有数字均带配对置信区间; 凡答案是“无显著差异”, 我们如实写明。

发布产物。模型权重与 model card (Meerkat-TRIZ-v1)；双金标基准 (100 + 300 题)；以及 meerkat-triz——可 pip 安装的评测 harness，把下文每一条教训固化为机检断言而非口头约定。

2. 系统与训练

基座。 Qwen3.6-35B-A3B (Apache-2.0)：总参 35B / 激活 3B, 40 层混合 Gated DeltaNet (线性注意力) 与 Gated Attention 块, 256 专家 MoE, thinking-native 对话模板。

适配器。 LoRA $r=64$, $\alpha=128$, dropout 0, BF16, 覆盖 12 个投影矩阵 (含 DeltaNet in_proj_* 族) ——可训练参数 84.66M (0.24%)。在单台桌面级统一内存机器 (DGX Spark GB10, 121GB) 上免量化训练。发布的 v1 模型 (内部代号 v5a) 在约 1.1 万条中文 TRIZ ChatML SFT 样本上完整训练 4 epochs / 5,548 steps; final train loss 0.604, eval loss 1.626。

数据管线演进。五个版本的本质是数据与质量门的故事，而非超参故事：v1 (2.7k 样本、无质量门 → 整体回退)、v2 (8.5k 多角度样本、基础门)、v3 (ARIZ 定向注入)、v4 (七道门漏斗, 11,001 → 5,739 条)、v4.1 (单变量 rebalance, 修复 concept_explanation 退化)、v5a (双风格/双解耦/分组划分、空 think 块保留——即发布模型)。每条线内超参冻结，保证每次对比只有一个移动变量。

3. 评测方法学

harness 对每个模型做双轨评分，两轨永不混合加权：

- **关键词轨：**逐题期望术语命中率 (子串匹配 + 人工维护别名表；报告别名表更新前/后双分数；漏判审计队列持续监控别名表本身)。
- **judge 轨：**LLM 评委 (钉死 moonshot-v1-32k, 温度 0 硬断言) 按四维 rubric 打 0—4 分。臂 A 反冗长 rubric + 输入不截断；臂 B 与基线在同长度桶内配对以控制长度偏置。发布后终审以三个外部评委逐字复跑了臂 A 协议 (§5.2)。

四条纪律，全部由代码强制：

1. **锚点谱系。** base 锚点 tag 必须属于 base_goldfix 谱系，否则 harness 直接退出 (一票否决)。双锚点一致性检查：锚点间 $|\Delta kw| > 0.2$ 的题数 $> 10\%$ 即冻结报警。
2. **空 think 块保留 (E0 铁律)。** 每题 prompt 冒烟断言保留 `<think>\n\n</think>` 块；剥离它正是当初污染基线的原因 (§4.1)。
3. **生成质量门。** think 残留/非空/中文占比/长度下限 (外加英文草稿检测)；不过门触发一次 bad_words_ids 兜底重生；持续 invalid 则冻结评测，而不是静默混入分数。
4. **统计协议。** 全部对比逐题配对：bootstrap (10,000 次, stdlib Random(42), 指纹自检) 95% CI、pass 率 Wilson CI、McNemar 精确检验。 $n < 30$ 子集标注“描述性”，不得独立否决。pairwise 评委强制 AB/BA 双序；位置不一致率 $> 10\%$ 自动作废单序数字。

4. 三类测量学故障（及其代价）

4.1 基线污染——一个实际是 -0.30 的“ $+1.00$ 提升”

连续三个版本，我们的报告都称微调相对基座有将近一个 judge 分的提升 ($+1.00$ [0.80, 1.19], McNemar $p=1.7e-12$)。这个信号是假的。harness 剥离了 prompt 中的空 think 块；失去“思考已结束”锚点的 thinking-native 基座，在 91/100 道金标题上输出未闭合的英文思考草稿——两条轨评的都是草稿。修复后（保留空块、生成后剥离闭合块），v4 对基座的 judge 差值反号为 -0.30 [-0.46 , -0.14], McNemar 方向随之翻转 ($55/4 \rightarrow 10/30$)。所有版本排序必须重推；“保留 v2”的门裁决在干净锚点下依然成立，但理由链与当初记录完全不同。

4.2 评委位置偏差达文献振幅两倍

一个做回答对比的 pairwise 评委，位置不一致率达 0.87 [0.79, 0.92]——放在第二位的候选赢下 81%；在干净锚点上该效应仍以 0.58 的不一致率存在。文献报告的摆动约 25pp，我们实测 62pp。此场景下任何单序 pairwise 结论都是噪声。双序合并由此成为唯一有效口径并以代码强制。另一方面，评委在 $T=0$ 下被证明**完全确定**（重复翻转率 0.000——对他处报告 13.6% 翻转率的反例），这正是我们“钉版评委 + 单次运行”协议站得住的原因。

4.3 双轨分歧——当两条轨投出相反的票

关键词轨与 judge 轨测的是不同构念（共享方差约 10%，逐题 Spearman $r \approx 0.32$ ）。迭代中两轨曾显著反向：v3 vs v2，关键词 $+0.0556$ （显著）而 judge -0.0682 （显著）——v3 学会了堆关键词，语义质量反而下降。我们还发现关键词轨对 ARIZ 步骤覆盖的漏判率高达 31.7%（英文/同义表述被漏判），此前据此报告的“v2 ARIZ 回退”实为伪影。由此沉淀的操作判据：**发布门必须双轨；任何单轨结论不得独立下判。**

5. 结果

5.1 发布模型 · v5 金标口径（300 题，逐题配对）

本节 judge 轨数字为同族（Moonshot）评委读数——异源评委终审见 §5.2，方向获确认但量级更小。

指标	base（干净锚点）	Meerkat-TRIZ-v1	配对差值 [95% CI]
关键词均值	0.6384	0.6383	-0.0001 [-0.017 , $+0.017$] 不显著
judge 臂 A 均值	3.0300	3.4233	$+0.3933$ [$+0.297$, $+0.490$] 显著
judge pass 率	0.843	0.947	McNemar $p=1.5e-05$

judge 子集增益: concept_explanation +0.733 [+0.467, +1.022]、innovation_assessment +0.600、contradiction_analysis +0.467、case_generation +0.378、ariz_guidance +0.317 (均显著); principle_recommendation +0.050 不显著。质量门 299/300 过门; overrefusal 0/300。训练集对双金标的污染扫描 (3-gram Jaccard $\geq$ 0.5): **0 题命中**。

5.2 异源评委终审 (发布后, 299 题配对)

发布后, 我们将臂 A 评委协议逐字复跑——同 rubric、同 prompt、T=0、同配对 bootstrap——换成三家外部厂商的评委: claude-sonnet-4-6 (Anthropic)、gpt-5.4 (OpenAI)、gemini-3.5-flash (Google)。一题在所有评委下均被服务商内容过滤拦截, 故 n=299。

评委	base 均分	v1 均分	配对差值 [95% CI]	显著
moonshot-v1-32k (同族参照)	3.030	3.423	+0.393 [+0.297, +0.490]	是
claude-sonnet-4-6	2.555	2.649	+0.094 [+0.020, +0.167]	是
gpt-5.4	2.301	2.405	+0.104 [+0.020, +0.184]	是
gemini-3.5-flash	2.871	2.823	-0.048 [-0.144, +0.045]	否

如何解读:

- **方向成立, 量级不成立。**三个外部评委中两个维持正方向且统计显著, 但量级约为同族读数的 1/4; 第三个未见显著差异。可辩护的头条结论是“三个外部评委中两个显著 (+0.09 ~ +0.10)” ; 同族 +0.39 中约 3/4 可归因于评委家族效应, 不得外推。
- **这是评分体系差异, 不是评委噪声。**三个外部评委互相逐题 Spearman 为 **0.63–0.75**, 而各自与 moonshot 仅 **0.27–0.31**。
- **concept_explanation 是最强共识**——v4.1 再平衡定向修复的子集, 在三个外部评委下 **全部显著** (+0.24 / +0.31 / +0.29)。修复真实有效, 且经外部验证。
- **观察项。**Gemini 对发布模型的 principle_recommendation 打分显著更低 (−0.31 [−0.53, −0.10]); 另两个评委未见显著差异。单一评委支持, 我们将其记为下一轮数据迭代的开放信号, 而非已确立的回退。

完整报告与原始数据：EXTERNAL_JUDGE_REVIEW.zh-CN.md (English) · external_review_result.json。

5.3 v4 金标口径六方对比 (100 题)

模型	关键词轨	judge 轨	judge pass 率
base (旧锚点, think 污染——仅供参考)	0.3661	1.5700	0.120
v2 (干净锚点)	0.5483	2.5800	0.620
v3	0.5716	2.2800	0.430
v4	0.5568	2.5700	0.630
v4.1	0.5289	2.6200	0.630
Meerkat-TRIZ-v1 (v5a)	0.5391	2.3600	0.600

v5a vs v2 配对：关键词 -0.0093 $[-0.062, +0.039]$ 不显著；judge -0.2200 $[-0.470, +0.010]$ 不显著——与内部最强基线统计打平。v4 harness 会剥离空 think 块（与 v5a 训练格式失配），judge 负方向部分可归因于此，“打平”应读作下界估计。v4.1 的 rebalance 在无显著代价下修复了 concept_explanation 退化（kw 差值 vs v2 -0.0397 $[-0.103, +0.025]$ ，CI 含 0）。

5.4 微调究竟带来了什么

干净锚点下，早期微调的真实效应是行为压缩：think 式长作答（约 3,250 字符）变为约 1/10 长度的直接作答，关键词覆盖持平，judge 轨质量略低于冗长的基座。v5a 线是首个把这种压缩转化为原生口径 judge 轨真实增益的版本——同时在旧口径上仍仅与 v2 打平。两个事实都写在 model card 里。我们未做外部模型对比，也不做任何此类宣称；§5.2 的终审改变的是评委，而非被对比的模型。

6. 局限

- **评委同族**：数据生成器与主评委同属 Moonshot 家族（声明为“同族弱异源”）。发布后异源终审 (§5.2) 在 2/3 外部评委下确认了提升方向，但量级约为同族读数的 1/4——同族绝对分不得跨评委家族外推。一个外部评委 (Gemini) 未检出整体增益，且对 principle_recommendation 给出显著负差；单一评委支持，我们将其记为开放信号而非已确立的回退。
- **功效**：100 题口径子集 $n=10-20$ ，全部为描述性；“与 v2 打平”意为“未检出显著差异”，而非已证等价。
- **长度混淆**：基座回答约长 10 倍，judge 的完整性维度天然偏好长答；臂 B（同长度桶）配对太少 (17/300)，未能完全控制。
- **单域、单基座、单 PEFT 配置**：仅验证中文 TRIZ 问答；未做 target_modules 消融。

- **基准发布形态**：公开基准不含参考答案（版权原因）；关键词轨可完整复现，judge 轨绝对分不可。

7. 可复现性与产物

- 模型：<https://huggingface.co/Meerkat-AI/Meerkat-TRIZ-v1>（适配器 + 含完整结论纪律的 model card）
- 基准：<https://huggingface.co/datasets/Meerkat-AI/triz-gold-benchmark>（question + keywords；CC-BY-NC-4.0）
- 代码：<https://github.com/coidea-sys/meerkat-triz> ——harness、冻结训练配置（configs/train_v5a.json）、方法学文档；CI 在每次推送时运行单元测试、免 GPU 全流程 dry-run 与决策门回溯验证。

确定性：贪心生成、T=0 评委（实测翻转率 0.000）、stdlib Random(42) bootstrap、每份结果内嵌配置快照。

8. 引用

```
@misc{meerkat-triz-whitepaper-2026,  
  title = {Meerkat-TRIZ: A TRIZ-Domain LoRA Fine-tune, and the Evaluation  
Infrastructure That Kept It Honest},  
  author = {Meerkat AI},  
  year  = {2026},  
  url   = {https://github.com/coidea-sys/meerkat-triz}  
}
```

测量学故障案例研究的学术版（拟定题：“When the Baseline Lies”）正在另行准备；本白皮书为发布配套文档与可引用数字的唯一来源。