

FDE 团队技术介绍 · 内部资料

Meerkat-TRIZ-v1

训练方法、评测证据与落地应用

TRIZ 领域首个公开发布的 LLM 微调模型
以及让它保持诚实的评测基础设施

Meerkat AI · 2026 年 8 月

产物: [HF 模型](#) Meerkat-AI/Meerkat-TRIZ-v1 · [基准](#) triz-gold-benchmark · [代码](#) github.com/coidea-sys/meerkat-triz

本文全部数字源自白皮书 v1.3、发货物 adapter_info.json 与部署运维记录, 可逐项复核

今天讲什么

- 01 为什么做：TRIZ 与企业创新的断层
- 02 是什么：模型、基座与发布产物
- 03 怎么训：数据管线、冻结超参与训练实况
- 04 怎么评：双轨 harness 与五类测量学故障
- 05 评得怎样：全部结果，包括打平的那个
- 06 怎么部署：DGX Spark 生产架构
- 07 怎么用：六类任务场景 · 企业视角（角色/行业/ workflows/话术）· FDE 接入指南
- 08 往哪走：路线图与开放问题

TRIZ：把创新从"灵光一现"变成"可查的方法"

TRIZ（发明问题解决理论）由根里奇·阿奇舒勒自 1946 年起，从数十万件专利的分析中提炼。核心洞察：**创新不是随机的天才灵光**——同样的技术矛盾在不同行业反复出现，解法遵循可复用的模式。

结构化工具体系

- 40 个发明原理 + 矛盾矩阵——解决技术矛盾（改善一个参数而不恶化另一个）
- 分离原理——处理物理矛盾
- ARIZ——重构与求解难题的完整算法
- 技术系统进化法则——路线图思考

产业现状：分发方式极原始

三星、西门子、GE、波音曾用 TRIZ 内训数以千计的工程师；在中国，TRIZ 是国家创新方法推广工作的组成部分。

$\sim 10^3$ 人

全球活跃 TRIZ 持证咨询师量级

$\sim 10^6$ 人

需要这套方法论的工程师量级

一家企业的 TRIZ 能力 $\approx$ 它养得起几个持证专家。方法论几乎只存在于昂贵的培训课程与咨询师身上。

为什么是微调，而不是提示词工程

此前的 LLM+TRIZ 工作全部是提示词工程。微调能买到三样提示词买不到的东西：

术语纪律

原理编号引用、分析步骤完整性，**固化进权重**，而不是在 prompt 里恳求。每次调用都稳定交付，不随 prompt 漂移。

行为风格

直接可执行的回答，而非冗长思考流：基座中位 3,242 字符的 think 式作答，被压缩到 **0.4× 篇幅**（1,344 字符）且关键词覆盖持平。

能力内嵌

"查书答题"与"学会方法"的区别——在案例生成等生成类任务上最明显：模型输出的是方法论的应用，而非检索结果的复述。

商业本质：微调模型把方法论的应用能力，从按人天计费的咨询服务，变成**边际成本为零的基础设施**。企业创新的瓶颈往往不是点子，而是问题表述——大多数工程团队在创意阶段之前就卡住了：说不清自己真正面对的矛盾是什么。常驻模型恰好在这个断点上起作用。

Meerkat-TRIZ-v1: 模型与发布产物

基座 · Qwen3.6-35B-A3B (Apache-2.0)

总参 / 激活	35B / 3B (MoE 稀疏激活)
架构	40 层混合 Gated DeltaNet (线性注意力) × Gated Attention, 256 专家 MoE
对话模板	thinking-native (空 think 块是格式锚点)

适配器 · LoRA (发货物实测)

秩 / α / dropout	$r=64, \alpha=128, \text{dropout } 0$
覆盖	12 个共享投影 (含 DeltaNet in_proj_* 族) 620 张量 = $310 \times \text{lora_A} + 310 \times \text{lora_B}$
可训练参数	84.66M (占 0.24%) · 全 BF16 非零
体积	169.4 MB, sha256 全文件记录

模型

HF: Meerkat-AI/Meerkat-TRIZ-v1, Apache-2.0, model card 含完整结论纪律 (含"打平"声明)

基准

triz-gold-benchmark: 双金标 100+300 题, 六类任务, CC-BY-NC-4.0 (版权原因不含参考答案)

代码

meerkat-triz: 可 pip 安装的评测 harness + 数据构建层 + 冻结训练配置 + 中英白皮书

v5a 数据管线：11,096 条训练样本怎么来的

① 语料构建

v2 检查点语料 + ARIZ 增强 + 合成数据，过门 1—5（含门 5 修复）→ gated corpus 8,613 条

② 种子扩写

三规则清洗 385→365；每粒种子 ×3 衍生物；styleC 长答 3,441/3,445（4 条未完结如实记录）

③ 双风格合并

同一 instruction 生成短答/长答双版本；safety 300 条（5 类 ×60，占比 ≤5% 断言）

④ 双重去污

3-gram Jaccard vs 参照集 A（金标 200）+ B（eval2 465 + probe 120）； $J \geq 0.5$ 剔除，[0.4,0.5) 人工审查队列；精确 brute-force，0 漏检

⑤ 分组划分

长短双风格、种子 ×3、v4 前缀 12 聚类 union-find 同组同侧；划分后 test/val vs train 交叉检查，命中整组移回 train

⑥ ChatML 渲染

E0 协议：空 think 块 **保留**（与生成侧一致，训练/推理格式一致优先）；>2048 token 丢弃

11,096

训练样本（+ 1,050 验证集），每一步计数、sha256、退化声明写入 MANIFEST.md 与 v5_data_report.json

0

训练集对双金标的污染命中（3-gram Jaccard ≥ 0.5 扫描）

双实现

独立复核：verify_build_v5.py 自包含重算去污/划分/终态安全网，与构建器数字完全一致（exit 0 = PASS）

五个版本的学费：这是数据与质量门的故事，不是超参故事

版本	数据策略	结果	教训
v1	2.7k 样本，无质量门	整体回退	没有门的数据是负债
v2	8.5k 多角度样本 + 基础门	成为最强基线	干净锚点下的内部标杆
v3	ARIZ 定向注入	双轨反向	关键词 +0.056（显著）但 judge -0.068（显著）：学会堆关键词，语义质量反降
v4	七道门漏斗 11,001→5,739	CE 退化	concept_explanation 子集受损，暴露"整体指标掩盖子集退化"
v4.1	单变量 rebalance	修复 CE	定向修复无显著代价（kw vs v2 差值 CI 含 0）
v5a	双风格/双解耦/分组划分 + E0 空 think 保留	发布模型	首个把行为压缩转化为原生口径真实增益的版本

每条线内超参冻结，保证每次对比只有一个移动变量——v1→v5a 的进步几乎全部来自数据与质量门，超参贡献为零。这条纪律由 configs/train_v5a.json 固化并随仓发布。

训练实况：桌面级机器上的 23 小时

硬件与效率

机器	NVIDIA DGX Spark GB10 (121GB 统一内存)
精度	BF16, 免量化训练
时长 / 显存峰值	23.0 小时 / 69.72 GB
吞吐	batch 1 × grad accum 8, 1,387 steps/epoch

35B MoE 全量微调不可行；LoRA 0.24% 参数让领域适配在桌面级机器上完成——这对客户的私有化部署同样是好消息。

过程与发货裁决 (adapter_info.json 实录)

训练	4 epochs / 5,548 steps 完整跑完, 未 early stop
损失	train 0.604 · eval 最低 1.5266 @ step 2700 (后段回升至 1.626, 典型过拟合曲线)
发货裁决	不发最后一版, 发最好的 checkpoint: shipped_from = best/ (step 2700, eval_loss 1.5266)
发货前体检	9 项全 PASS: 620 张量、310/310 A/B、全 BF16 非零、sha256 记录

v5b 的教训 (已固化进训练代码): 后续 v5b 实验发现续跑时 LoRA dtype 漂移会导致权重异常——train.py 已加入 `_LoraDtypeRecastCallback` 续跑校正 + 发货前 safetensors BF16 兜底校正, 开源仓与内部管线逐行对齐。

评测 harness：双轨评分，四条机检纪律

两条永不混合加权的轨

- **关键词轨**：逐题期望术语命中率（子串 + 人工别名表；报告别名表更新前/后双分数；漏判审计队列监控别名表本身）
- **judge 轨**：LLM 评委四维 rubric 打 0—4 分（钉版 + T=0 硬断言）；臂 A 反冗长不截断，臂 B 同长度桶配对

统计协议

- 全部对比逐题配对：bootstrap 10,000 次（stdlib Random(42)，指纹自检）95% CI
- pass 率 Wilson CI + McNemar 精确检验；n<30 子集标"描述性"
- pairwise 强制 AB/BA 双序；位置不一致率 >10% 自动作废单序

四条纪律，全部由代码强制

① 锚点谱系	base 锚点 tag 非 base_goldfix 谱系 → exit 2 一票否决；双锚点 $\Delta kw > 0.2$ 题数 >10% → 冻结报警
② E0 铁律	每题生成前冒烟断言空 think 块保留；剥离即污染 (§故障 1 的根源)
③ 生成质量门	think 残留/非空/中文占比/长度/英文草稿五道门 + 一次兜底重生成；持续 invalid 冻结评测而非静默混入
④ 拒答监控	拒答模板命中率 >2% 不过门 (v5a 实测 0/300)

确定性：贪心生成、T=0 评委（同族直连实测翻转率 0.000）、每份结果内嵌配置快照——同环境重跑逐位相同。

五类测量学故障——每一类都足以反转或作废结论

故障	事实	代价 / 沉淀的门规
1. 基线污染	harness 剥离了 thinking-native 基座必需的空 think 块 → 基座 91/100 题输出未闭合英文思考草稿，两条轨评的都是草稿	连续三个版本的 "+1.00 提升" 修复后反号为 -0.30 ；E0 铁律入代码
2. 评委位置偏差	pairwise 评委位置不一致率 0.87：放第二位的候选赢 81%；文献摆动约 25pp，我们实测 62pp	任何单序 pairwise 结论都是噪声 → AB/BA 双序合并成为唯一有效口径
3. 双轨系统性分歧	关键词轨与 judge 轨仅共享约 10% 方差 (Spearman $r \approx 0.32$)；v3 两轨显著反向；ARIZ 覆盖漏判率 31.7%	门规：发布门必须双轨，任何单轨结论不得独立下判
4. 同族评委膨胀	评委与数据生成器同族 (Moonshot)；异源终审 (Claude/GPT/Gemini 逐字复刻协议) 方向确认但量级仅约 1/4	同族 +0.39 中约 3/4 是评委家族效应；外部面板进决策门
5. 长度混淆	base 篇幅 2.4x，rubric 惩罚冗长；等长对照下同族差值归零 (-0.07 ns)，而 base 仅靠压长指令自身 +0.46	门规 D5：judge 显著结论必须附等长对照；D6：非确定评委结论附复跑噪声合成 CI

对 FDE 的意义：客户拿任何"微调提升 X 分"的宣称来问，我们有一套经过实战检验的审查清单——先查 prompt 渲染，再查评委构成，再查长度分布，最后才谈数字。

结果①：v5 金标口径（300 题，逐题配对）


本表 judge 轨为同族（Moonshot）评委读数——异源终审见下页，方向获确认、量级更小。我们把它放在第一页，也把它打上标签。

指标	base	v1	配对差值 [95% CI]
关键词均值	0.6384	0.6383	-0.0001 [-0.017, +0.017] 持平
judge 臂A 均值	3.0300	3.4233	+0.3933 [+0.297, +0.490] 显著*
judge pass 率	0.843	0.947	McNemar p=1.5e-05

质量门 299/300 过门 · overrefusal 0/300 · 训练集对双金标污染扫描 0 命中

* 同族读数：后续证明基本为长度伪影 + 约 3/4 家族效应，不得外推

judge 子集增益（同族读数）



结果②：换三个外部评委 + 等长对照，结论才真正钉死

异源评委终审（299 题配对，协议逐字复刻，仅换评委）

评委	无约束		等长臂	
moonshot（同族参照）	+0.393	家族效应	-0.070	消失
claude-sonnet-4-6	+0.094	显著	+0.187	显著
gpt-5.4	+0.104	显著	+0.271	显著
gemini-3.5-flash	-0.048	不显著	+0.025	不显著

外部评委互相 Spearman 0.63—0.75，与 moonshot 仅 0.27—0.31——这是评分体系差异，不是噪声。显著结论均已过复跑噪声合成 CI（门规 D6）。

等长对照揭示的机制

让 base 按发布模型的逐题长度目标重答 300 题（实际超写 1.29×，如实报告）：

- 同族差值 完全消失（-0.07 ns）——同族头条基本全是长度伪影
- base 仅靠"写短"指令自身 +0.46——反冗长 rubric 一直在尽职
- 外部评委反而给压短的 base 降分——它们奖励展开阐述，base 的长篇本身在买分
- 等长下微调的关键词覆盖显著高于 base (+0.023)：base 被迫写短时丢覆盖，微调模型不会

现行发布口径：等长预算下经外部验证的质量优势（2/3 外部评委 +0.19/+0.27），以 0.4× 自然篇幅交付，并保住 base 被迫写短时保不住的关键词覆盖。

结果③：v4 金标六方对比（100 题）——打平也写在 model card 里

模型	关键词轨	judge 轨	judge pass 率	备注
base (旧锚点, think 污染)	0.3661	1.5700	0.120	仅供参考——这就是被污染的基线长什么样
v2 (干净锚点, 最强基线)	0.5483	2.5800	0.620	
v3	0.5716	2.2800	0.430	堆关键词的双轨反向案例
v4	0.5568	2.5700	0.630	
v4.1	0.5289	2.6200	0.630	CE 定向修复, 无显著代价
Meerkat-TRIZ-v1 (v5a)	0.5391	2.3600	0.600	

v5a vs v2 配对：关键词 $-0.009 [-0.062, +0.039]$ 不显著；judge $-0.220 [-0.470, +0.010]$ 不显著——与内部最强基线统计打平。v4 harness 剥离空 think 块（与 v5a 训练格式失配），负方向部分可归因于此，"打平"应读作下界估计。

为什么敢把打平写出来："打平"意为"未检出显著差异"，而非已证等价。100 题口径子集 $n=10-20$ 全为描述性。诚实口径是 FDE 面对客户技术质询时最硬的底气——我们的每个数字都有配对 CI，每个否定结论都如实标注。

微调到底带来了什么

0.4×

回答篇幅：中位 1,344 vs 3,242 字符
think 式长作答 → 直接可执行作答

+0.19 / +0.27

等长预算下的 judge 增益
2/3 外部评委统计显著（复跑噪声合成 CI 后仍成立）


+0.023

等长下关键词覆盖显著高于 base
base 写短就丢的术语覆盖，微调模型保了下来

机制理解

- **行为压缩是主线**：微调把"先想后答"的冗长推理流，压成结构化直接作答——这对企业场景（API 计费、时延、可读性）本身就是价值，与质量增益相互独立。
- **外部评委与外部评委才是仪器**：同族读数 +0.39 被证明是"长度伪影 + 家族效应"的复合物；外部等长面板（+0.19/+0.27 显著）才把真实内容增益隔离出来。
- **最强共识是定向修复的 concept_explanation**：v4.1 再平衡修复的子集，在三个外部评委下全部显著（+0.24/+0.31/+0.29）——证明"测量 → 定向数据 → 门验收"的迭代闭环真实有效。
- **被否决的 v5b 也已回溯溶解**：其全部表观增益/损失经等长对照证明同为长度表面效应——行为改变是真的，对 base 的可测效果全是长度现象。

生产部署：DGX Spark 上的完整栈



生成参数（服务端默认）

```
{
  "temperature": 0.6, "top_p": 0.95,
  "repetition_penalty": 1.05,
  "max_new_tokens": 16384
}
# 模型名: Meerkat-TRIZ-v1 (同时挂 Qwen3.6-35B-A3B-NVFP4 基座用于 A/B)
```

运维要点（全部写入 MEERKAT-OPS.md）

- **推理长度**：reasoning 系模型且 LoRA 思维链更长，max_tokens 建议 ≥ 4096 ，否则思考耗尽额度导致 content 为空
- **网络**：8000 无认证，仅 Tailscale/局域网，不暴露公网
- **量化口径**：部署为"BF16 训练、NVFP4 基座 + BF16 LoRA 热挂"——与训练评测口径不同，发布前已在本地金标补测确认无漂移
- **多用户**：Open WebUI 自助注册，新用户 pending 角色，admin 审批后可用

FDE 接入指南：三条路径

① 演示

Open WebUI :12001 (客户开账号 → admin 审批)
或 pi Web UI :12002 现场操作。默认模型已是
Meerkat-TRIZ-v1, 中文回答。

② API 集成

OpenAI 兼容端点 :8000/v1, 模型名 **Meerkat-TRIZ-v1**。客户系统 (IM bot、工单、知识库) 直接对接。

③ 私有化

客户自有 GPU: HF 拉取基座 + 169MB LoRA,
peft 热挂; 或打包 vLLM 容器镜像交付。

```
# 路径②: OpenAI 兼容调用 (DGX Spark 实例)
import openai
client = openai.OpenAI(base_url="http://<dgx-spark>:8000/v1", api_key="local")
resp = client.chat.completions.create(
    model="Meerkat-TRIZ-v1",
    messages=[{"role": "user",
                "content": "我们的锂电池想提升能量密度, 但安全测试通不过, 该用哪些发明原理? "}],
    temperature=0.6, top_p=0.95, max_tokens=4096)  # ⚠ max_tokens 别低于 4096
```

两条红线 (写进 model card, 也是 FDE 话术): ① 保留空 think 块 (E0 铁律, 剥离 = 可测量的质量损害); ② max_tokens ≥ 4096 (思维链长, 额度不够会拿到空 content)。这两条犯了, 客户会以为模型坏了——其实是用法错了。

六类任务场景与演示脚本

任务类型	客户语言	演示提问示例	子集证据
concept_explanation	概念讲解	"什么是技术矛盾？和物理矛盾有什么区别？"	三外部评委全显著 +0.24/+0.31/+0.29
principle_recommendation	原理推荐	"提升屏幕亮度但功耗超标，用哪几条原理？"	入门层规模化主力（观察项：Gemini 单评委负差，跟进中）
contradiction_analysis	矛盾分析	"帮我把这个散热问题表述成标准技术矛盾"	同族 +0.467 显著
ariz_guidance	ARIZ 引导	"带我用 ARIZ 走一遍这个良率问题"	同族 +0.317 显著
innovation_assessment	创新评估	"评估这个专利规避方案的创新等级"	同族 +0.600 显著
case_generation	案例生成	"给一个用原理 35（参数变化）解决包装难题的案例"	同族 +0.378 显著

价值定位（对客户说）：在需要的时刻在场（设计评审前夜凌晨两点）、入门层规模化（方法论素养从培训预算条目降为一次 API 调用）、成为专家的初稿层（模型起草、咨询师把关，专家时间从"生产"转移到"判断"）。

边界声明（也必须说）：这是助手，不是替代。复杂创新项目仍需人类咨询师。改变的是下限——每个工程师都有了一位懂方法论的同事，专家获得了杠杆。

对客户讲：不是更大的模型，而是受过 TRIZ 训练的创新工程助手

通用大模型

知识面广，能聊很多话题；但每次都要靠提示词告诉它"请扮演 TRIZ 专家"——换一个用户、换一个问题，输出就漂移。

专业化 · 不靠提示词"装懂"

术语纪律、分析步骤、原理推荐方式固化进模型；换问题、换用户，输出仍一致。

可信评测 · 不"自己说自己好"

同族 +0.39 不作为质量证据（等长后基本消失）；正式口径用外部评委等长验证：Claude/GPT 显著为正。好看的说法让位于可辩护的说法。

Meerkat-TRIZ-v1

把 TRIZ 的术语、分析步骤和推荐方式**训练进权重**。不是临时扮演，而是受过系统训练——输出一致性不依赖提示词手艺。

效率 · 更短但不靠省略

3,242 字 → 1,344 字：工程师读起来更快，API 成本更低；关键是 base 被迫写短时丢覆盖，v1 保得住。

客观指标 · 不只会"说好听话"

关键词轨不调用 LLM 评委，只检查 TRIZ 术语是否出现：v1 与基座同为 0.638，高于擂台中的 GPT/Claude/Gemini 参赛模型——窄领域专业化训练真实有效。

按角色：同一模型，九类企业用户的不同价值

CEO / 总经理

"AI 概念还是创新能力？"

把依赖少数专家的 TRIZ 方法变成员工随时可调用的**基础设施**；专家时间从重复讲解转向判断决策。

CTO / 技术负责人

"能接入现有系统吗？成本高吗？"

169MB LoRA，不重训 35B；挂在现有模型服务上，以较低成本获得可内部化的领域助手。

研发总监 / 总工程师

"真能帮工程师解决问题吗？"

问题澄清、矛盾分析、原理推荐、方案草稿、ARIZ 引导——不做最终设计，但让团队更快进入有结构的讨论。

创新负责人

"已有创新流程，加什么价值？"

把头脑风暴变成围绕矛盾、资源、发明原理的**方法论驱动方案生成**。

知识产权 / 专利团队

"能帮专利布局吗？"

从矛盾、替代原理、系统进化角度扩展思路，辅助交底书初稿与规避设计讨论。**边界：不是专利检索系统，不替代律师意见。**

产品经理

"我不懂 TRIZ，能帮我什么？"

把"要更轻但不能牺牲强度"这类模糊诉求整理成可讨论的技术矛盾——**产品语言转工程语言**。

工艺 / 制造 / 质量工程师

"现场问题能用吗？"

密封与散热、轻量化与强度、成本与可靠性、效率与噪音——TRIZ 擅长的权衡问题，帮现场经验进入结构化改进。

HR / 培训负责人

"能降低培训成本吗？"

TRIZ 入门教练：解释概念、生成练习、批改答案、提供案例——培训不必每次都从外部顾问开始。

咨询顾问 / 专家委员会

"会替代专家吗？"

不会。它是专家的初级助理：结构化初稿、扩展候选方向、检查术语步骤；**判断、取舍、背书仍归专家**。

按行业：优先选"一个参数变好、另一个变差"的场景

汽车与零部件

轻量化、安全、成本之间的权衡

- 轻量化 vs 碰撞安全
- 续航 vs 成本
- 密封性 vs 散热

电子与消费电子

小型化与可靠性的长期拉扯

- 更薄 vs 更强散热
- 高集成度 vs 可维修性
- 防水 vs 声学性能

工业装备

把经验调参变成原理驱动

- 提高速度 vs 降低振动
- 自动化 vs 维护复杂度
- 精度 vs 成本

能源、材料与化工

辅助技术路线讨论

- 能量密度 vs 安全性
- 催化效率 vs 成本
- 材料强度 vs 可加工性

医疗与精密设备

设计输入阶段的结构化预分析

- 小型化 vs 操作稳定性
- 无菌要求 vs 装配效率
- 安全性 vs 使用便利性

软件与智能硬件

把产品矛盾说清楚

- 功能更多 vs 产品更简单
- 自动化 vs 用户可控性
- 数据丰富 vs 隐私保护

企业 workflows、对外话术与边界



对外介绍时可直接用的三句话

给管理层：把 TRIZ 从少数专家手里的方法论，变成可规模化部署的 AI 基础设施；显著提高工程师进入结构化创新讨论的速度。

给技术团队：面向 TRIZ 微调的 35B LoRA；300 题金标上以 0.4× 篇幅交付，等长对照下获 2/3 外部评委显著质量确认。

给工程团队：把它当随时在线的 TRIZ 助教：定义矛盾、推荐原理、生成草稿；最终判断仍由工程师和专家完成。

对外始终说清楚的边界

- 目前主要面向中文 TRIZ 问答与创新分析
- 不是通用大模型的全面替代品
- 不是专利检索系统，不替代律师意见
- 不替代实验、仿真、安全验证与专家评审
- 优势宣称限定在公开评测口径内，不外推成"全面超过所有大模型"

这些边界不是削弱说服力，而是让企业客户敢相信。最准确的定位：把一个高价值、低供给的专业方法域，做成可部署、可测量、可复现的模型能力。

路线图：先证明是真的，再让它变大

阶段	动作	状态 / 判据
已完成	异源评委终审 (Claude/GPT/Gemini 面板) · 等长对照 · 通用能力探针 (120 题 vs base) · 决策门多评委化 (Moonshot 主轨 + 外部复核轨)	已入发布口径
数据侧	principle_recommendation 定向补强 (v5b 教训: 先归因、双轨过门、必附等长对照) · case_generation E2 式归因 · 专利语料升级——专利是天然 TRIZ 素材 (Altshuller 本人路径), 版权形态友好, 既扩容又改善可发布性	下一代主线
训练侧	E5 消融: 路由专家覆盖 (现 LoRA 只挂 12 个共享投影 0.24%, 256 个路由专家未动; 专家感知 LoRA 是一号技术悬念) · rank 消融 r=32/128	未启动
偏好优化	DPO: 用 judge 分构造偏好对——但须等异源面板验证 judge 可靠性之后, 否则是在蒸馏评委的癖好而非质量	等前置条件
明确不做	❌ 追关键词轨 (已持平, 且 v3 证明堆词反噬 judge 轨) ❌ 调超参 (四条线冻结证据: 超参不是杠杆) ❌ 更大 base / 全参微调 (无证据是瓶颈, 且破坏单变量可比性)	纪律

学术线：测量学故障案例研究 ("When the Baseline Lies") arXiv 论文在备；白皮书 v1.3 为可引用数字的唯一来源。

总结

三句话带走

- ① 我们交付的不是"一个微调模型", 而是**模型 + 基准 + 评测纪律**三件套——后者才是面对客户技术质询时最硬的资产。
- ② 经外部验证的诚实口径: **等长预算下质量显著更好 (2/3 外部评委)**, 以 **0.4x 篇幅交付, 关键词覆盖更稳**; 旧口径与最强基线打平——这句话同样写在 model card 里。
- ③ 落地路径已通: DGX Spark 生产栈在跑, OpenAI 兼容 API + 审批制 WebUI + 周回流管线; FDE 只需记住两条红线——**保留空 think 块、max_tokens ≥ 4096**。

参考: 白皮书 v1.3 (中英) · adapter_info.json · MEERKAT-OPS.md · 本页数字均可逐项复核

Q & A · Meerkat AI · 2026-08